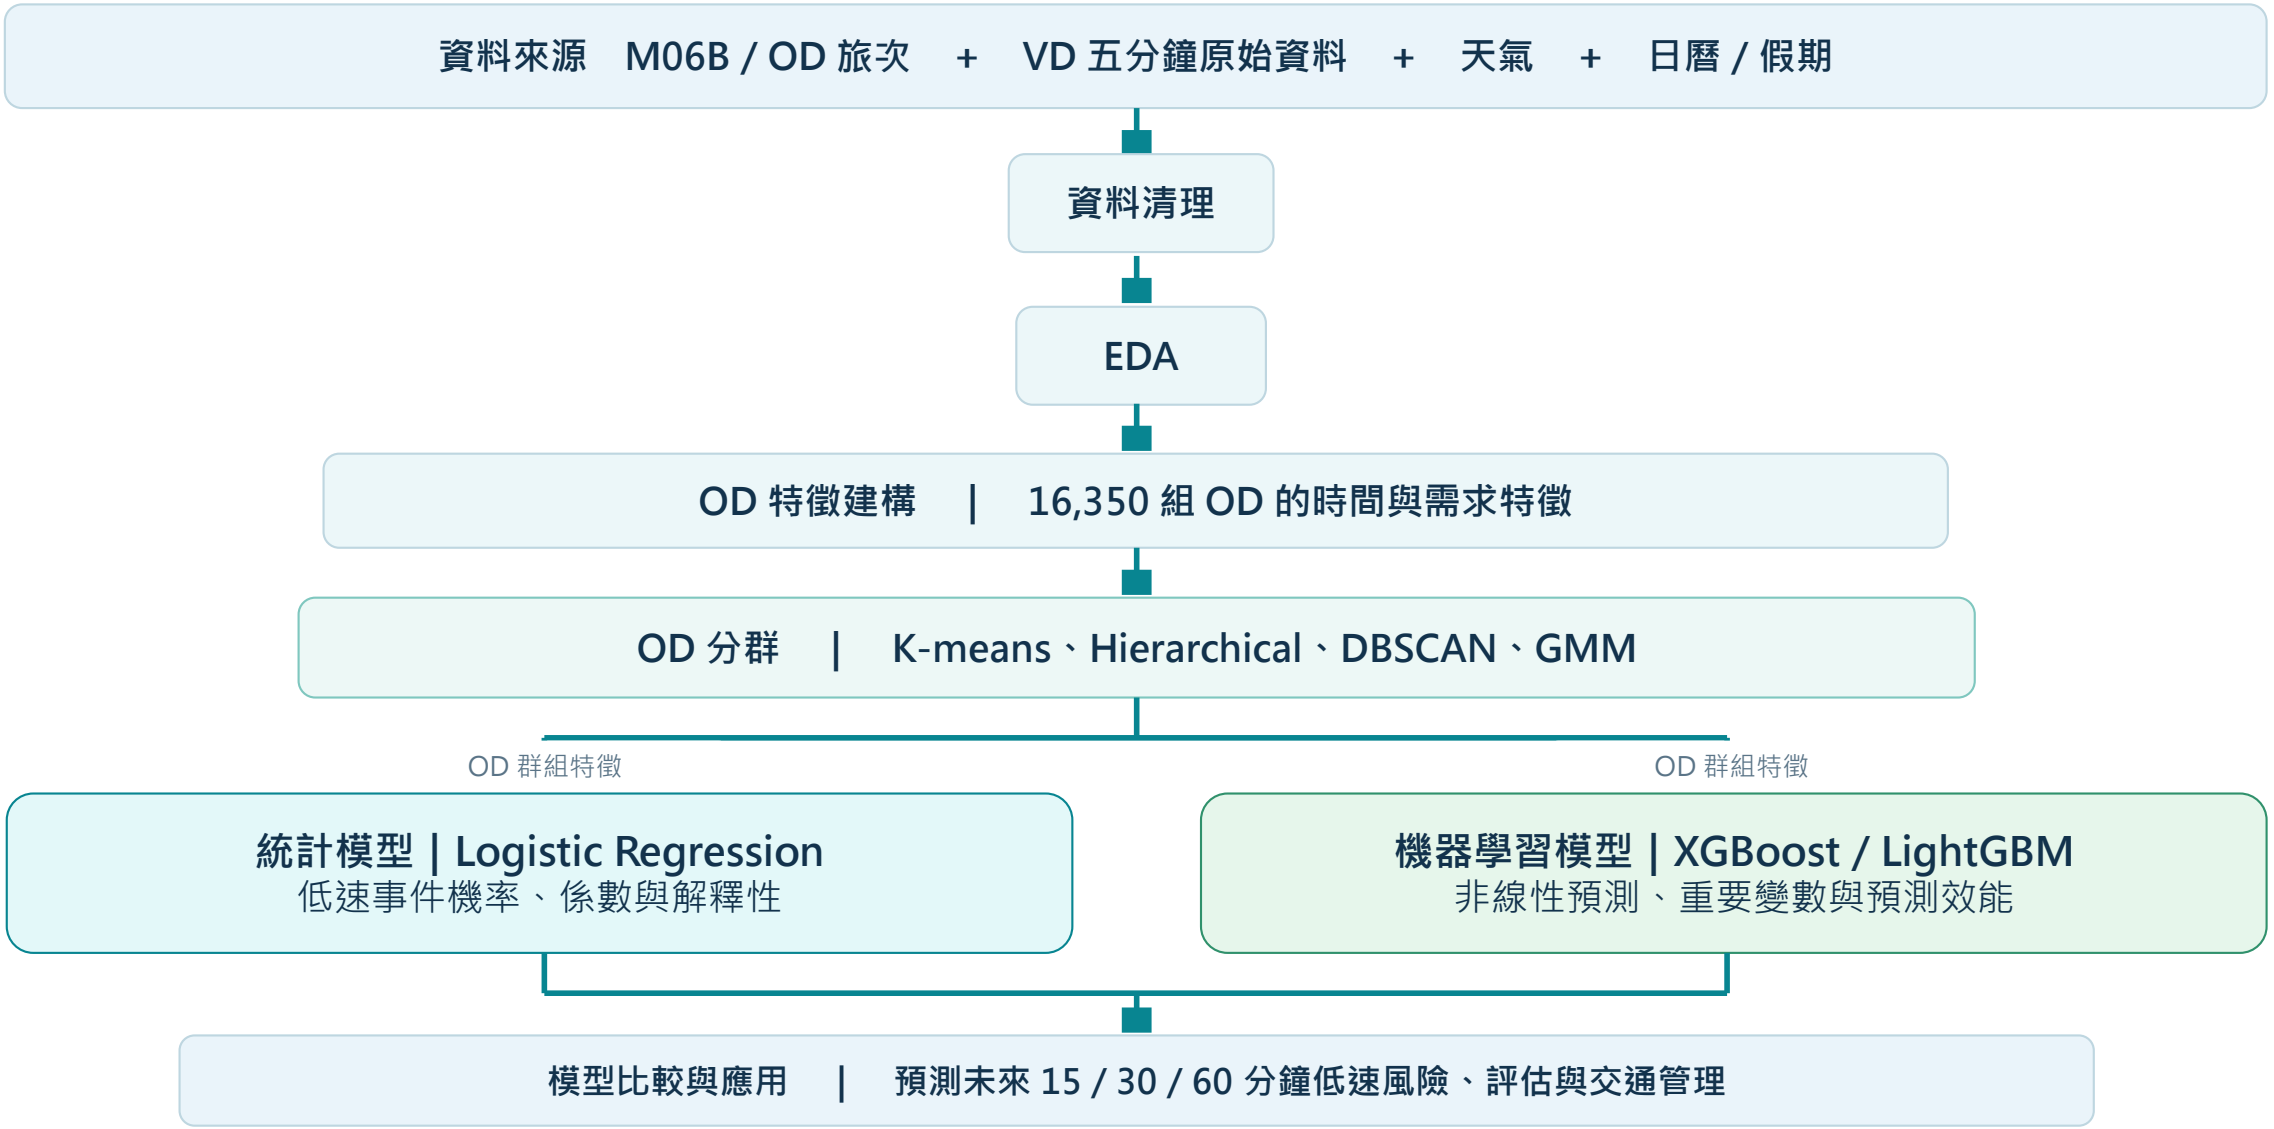
國道三號瓶頸路段之

交通需求探索與預測方法探討

以大溪 - 龍潭北向路段為例 | 統計實務專題進度報告

組員:鍾艾珊、鄭筱蓓、陳昆侑


資料來源　M06B / OD 旅次　+　VD 五分鐘原始資料　+　天氣　+　日曆 / 假期
資料清理
EDA
OD 特徵建構　|　16,350 組 OD 的時間與需求特徵
OD 分群　|　K-means、Hierarchical、DBSCAN、GMM
OD 群組特徵
OD 群組特徵
統計模型 | Logistic Regression
低速事件機率、係數與解釋性
機器學習模型 | XGBoost / LightGBM
非線性預測、重要變數與預測效能
模型比較與應用　|　預測未來 15 / 30 / 60 分鐘低速風險、評估與交通管理

研究問題：需求不是單一「總車流量」

需求發生於何時？	比較平日、週末、連假與不同時段的需求
哪些旅次形成需求？	辨識主要 OD、旅次距離、車種與重複出現車輛
外部情境有何差異？	比較日期、假期階段與氣象條件下的需求
如何銜接模型？	將 16,350 組 OD 歸納成需求模式，再對齊 VD 交通狀態

研究範圍與三個觀測層級

M06B 旅次紀錄整合瓶頸通過時間、VD Speed / Occupancy 與氣象欄位

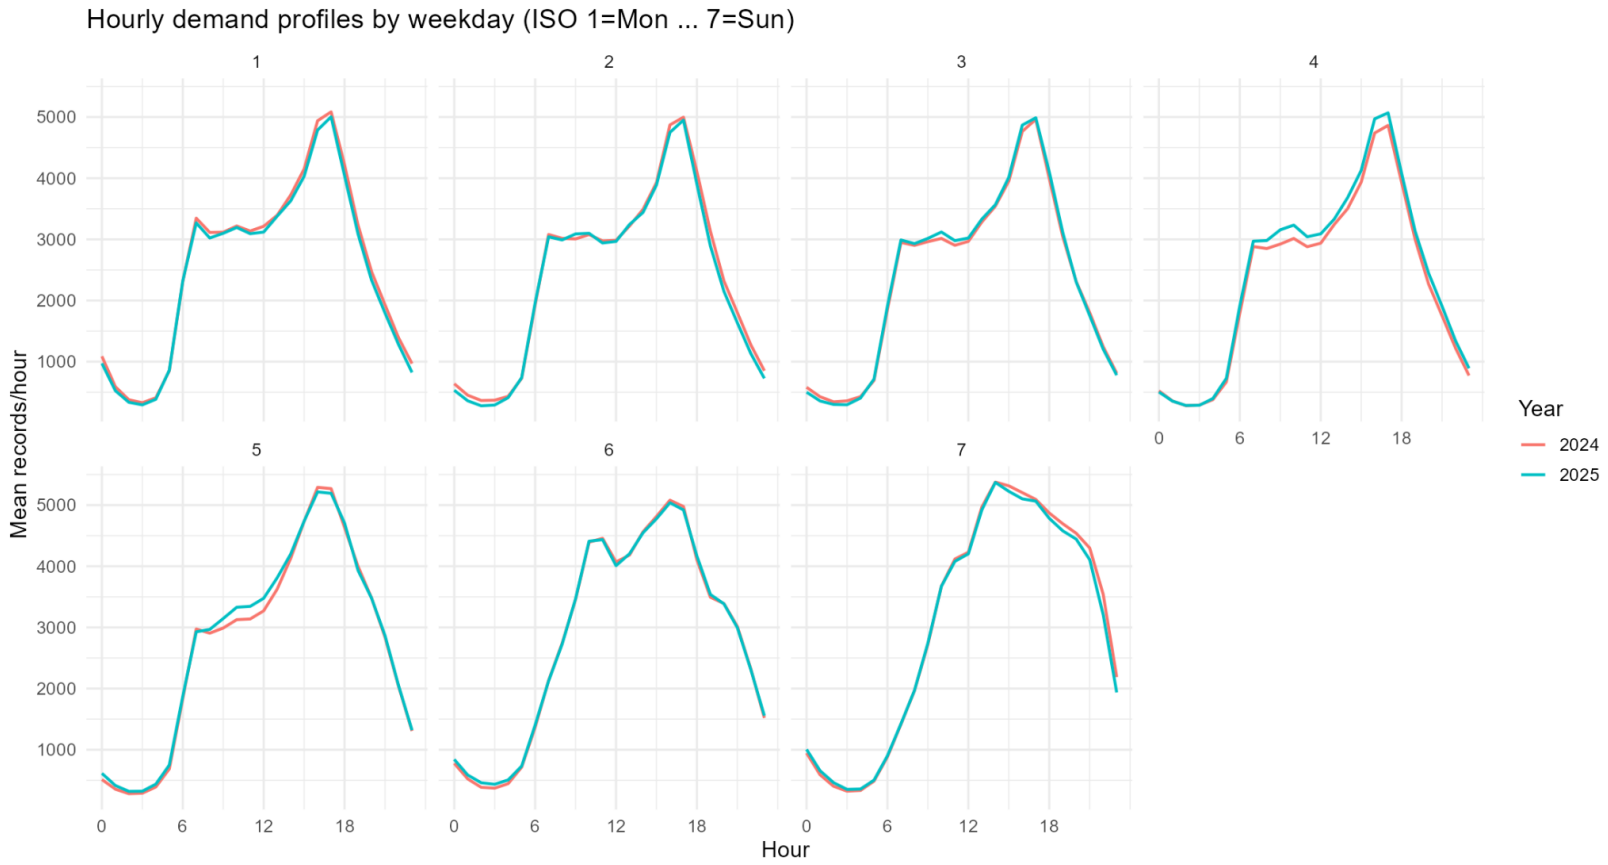
45,150,592
資料筆數

16,350
門架 OD 組合

731 天
2024–2025

變數類別	欄位數	主要欄位
車輛與 OD 旅次	8	VehicleID、VehicleType、GantryO/D、TripLength 等
日期與瓶頸時間	3	BottleneckTime、WeekdayNum、DayType
天氣資訊	4	Temperature、Dewpoint、Precipitation、WindSpeed
VD 速度	5	5 個 VD Speed 欄位
VD 佔有率	5	5 個 VD Occupancy 欄位
合計	25	

星期日需求最高，尖峰時間亦較平日提前



週一～四

17:00

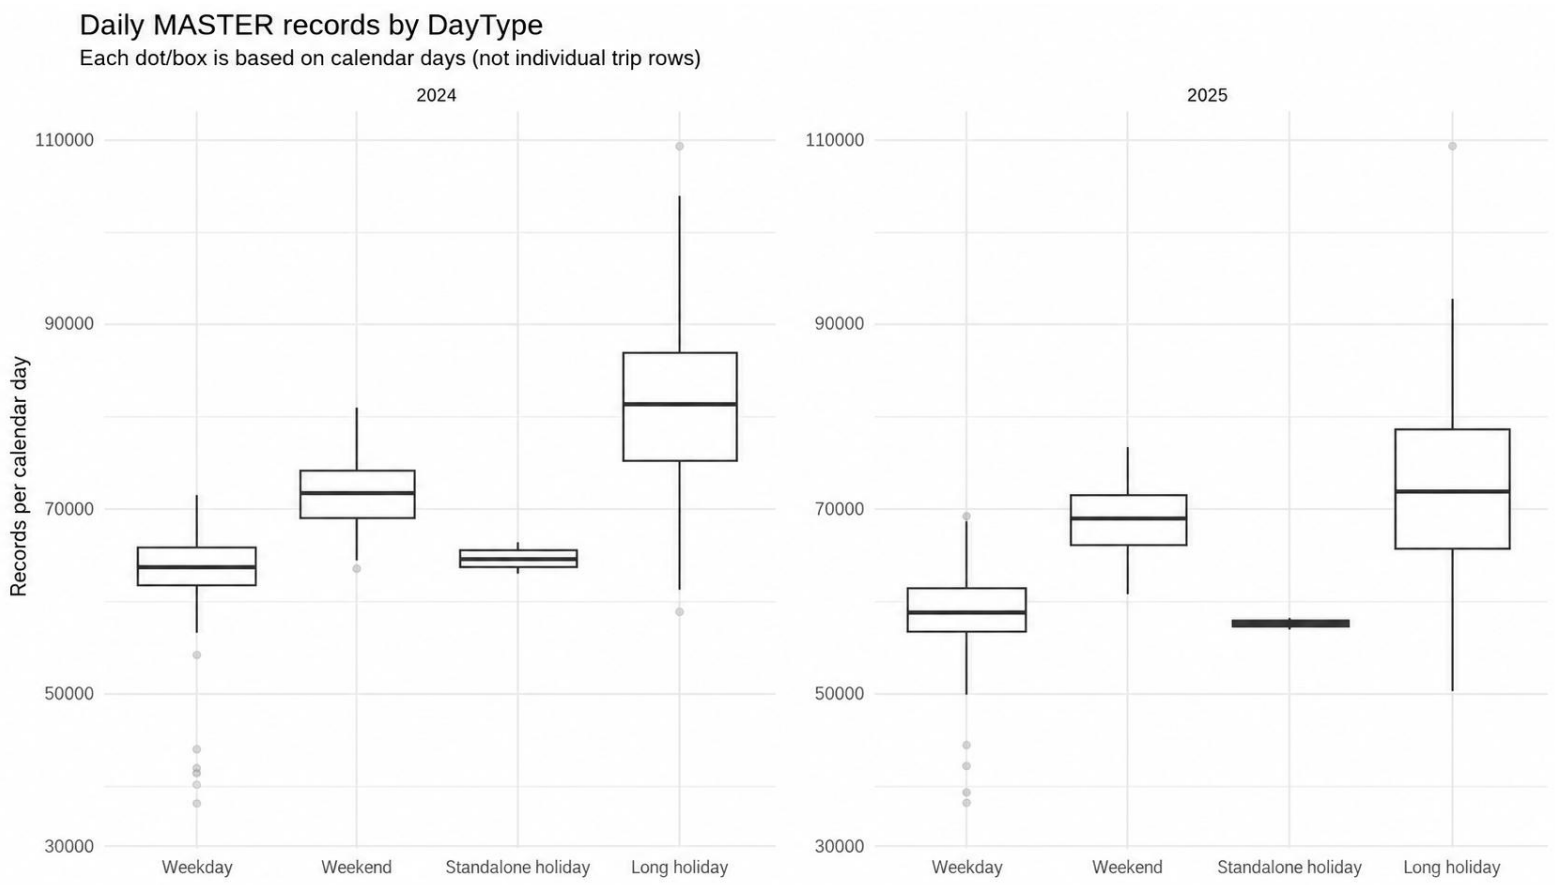
週五與週六

16:00

週日：14:00

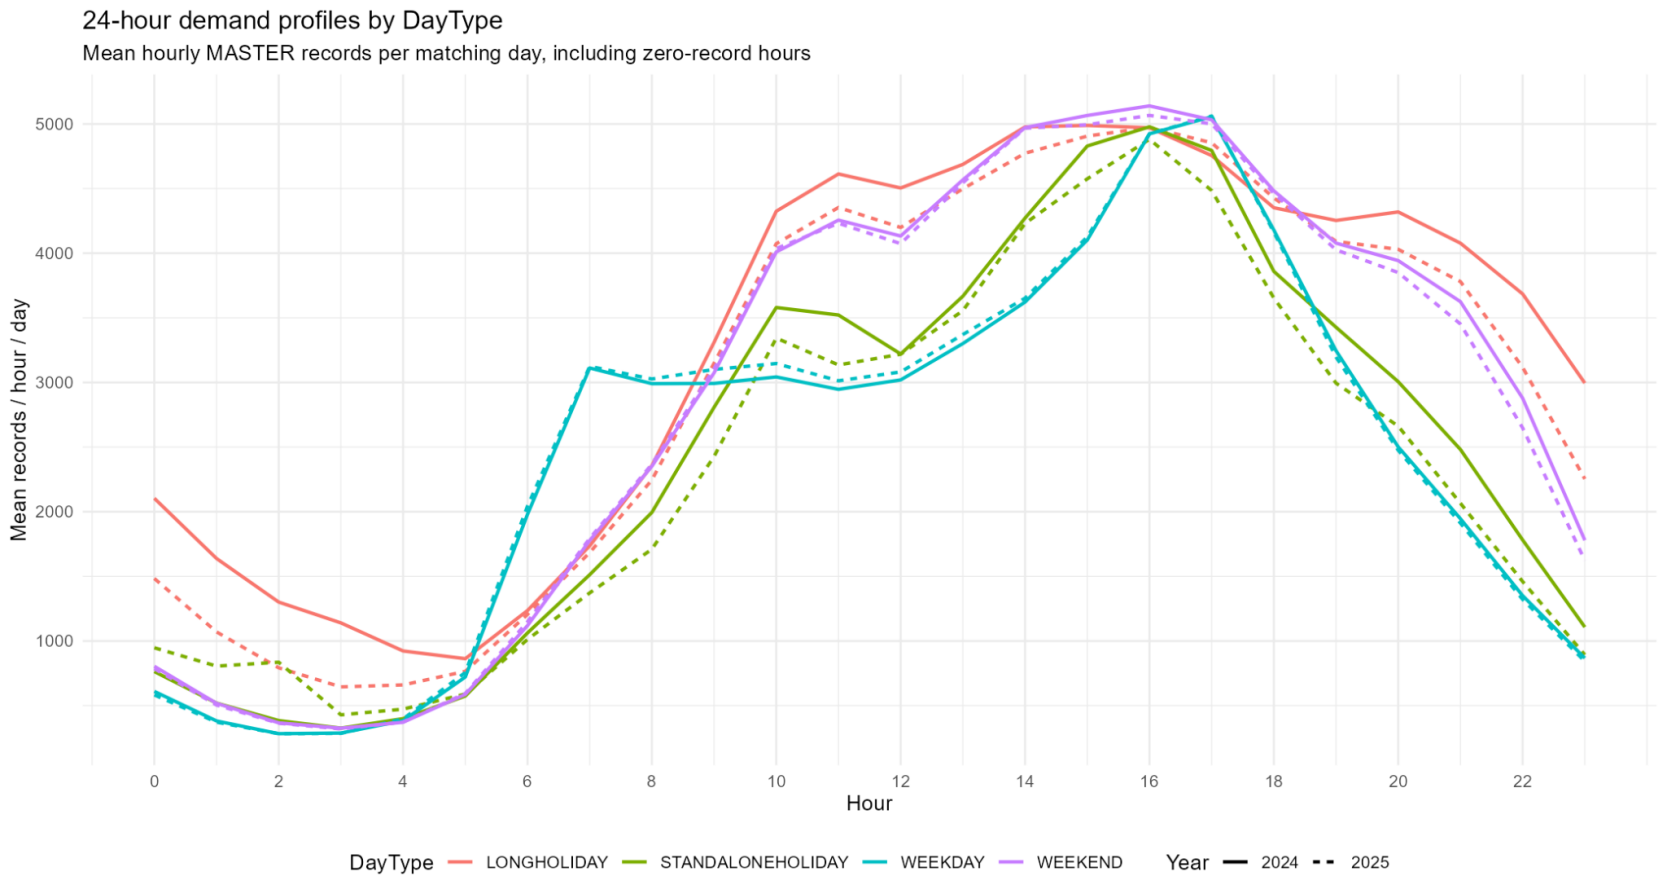
提醒：週末合併曲線不會等於「星期日」曲線。

四種日期類型的每日需求分布



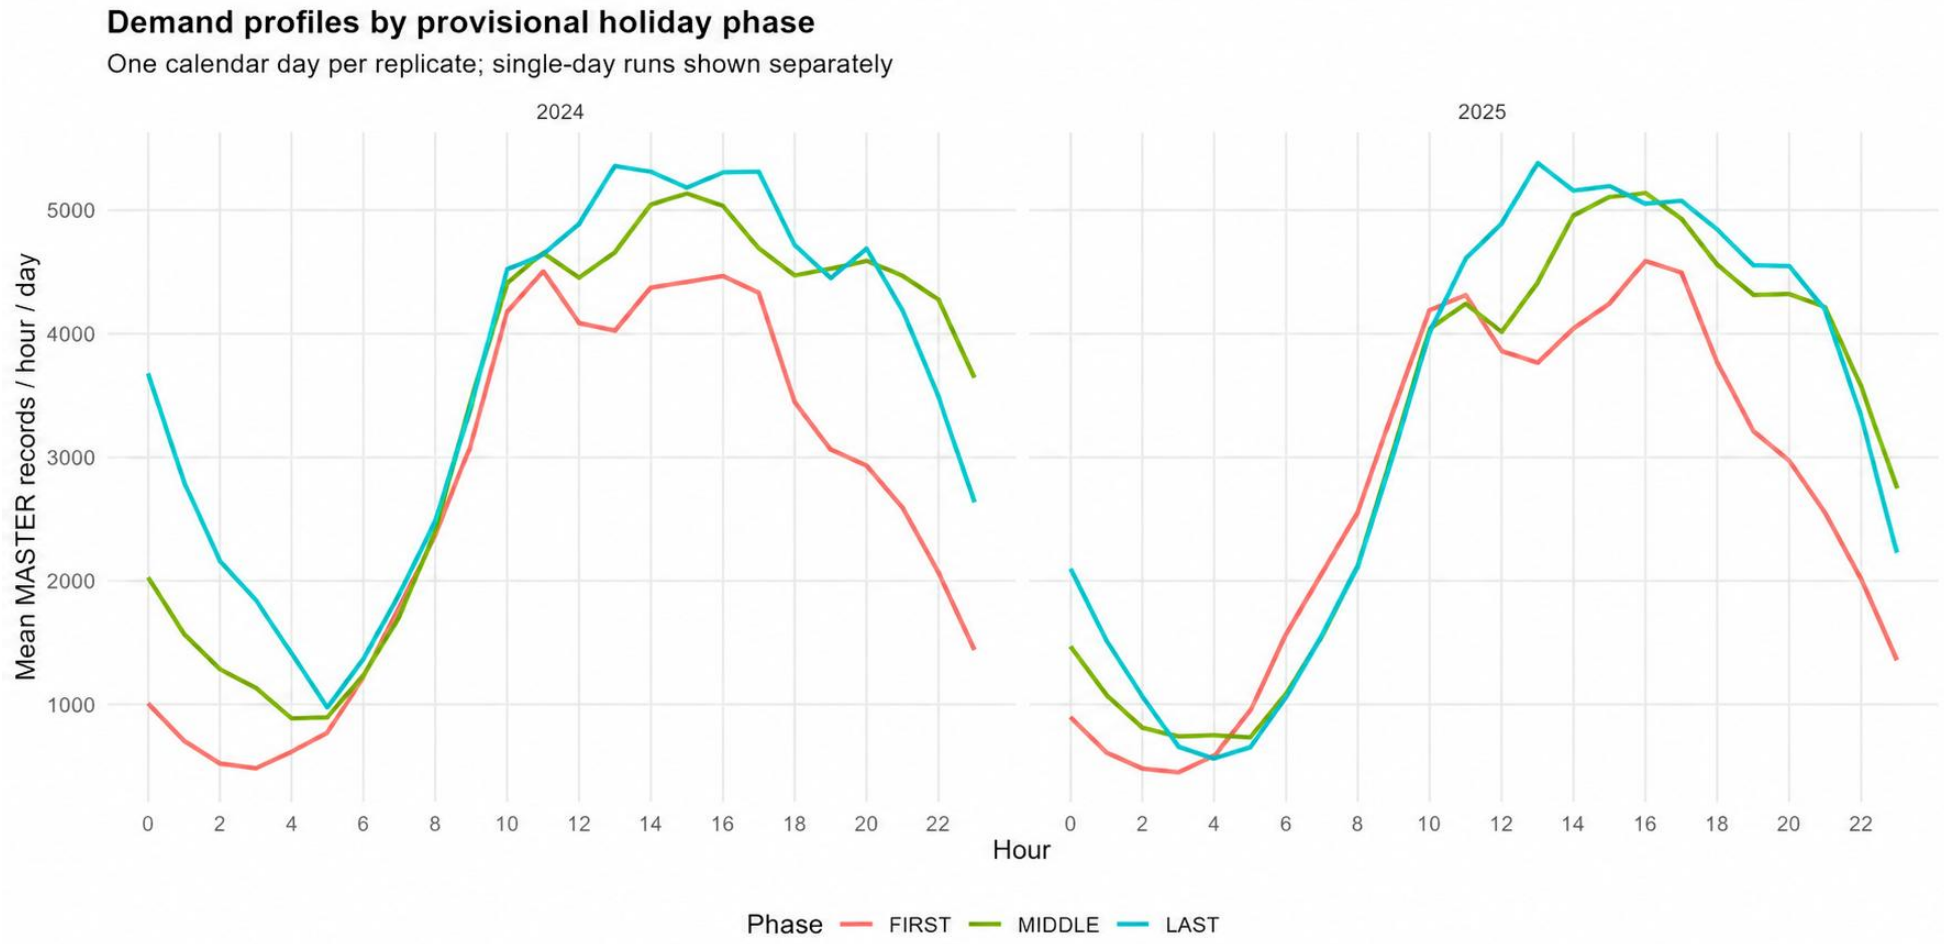
連假的平均每日需求較高；單日假日樣本極少。

連假不只是需求高，需求也維持較長時段



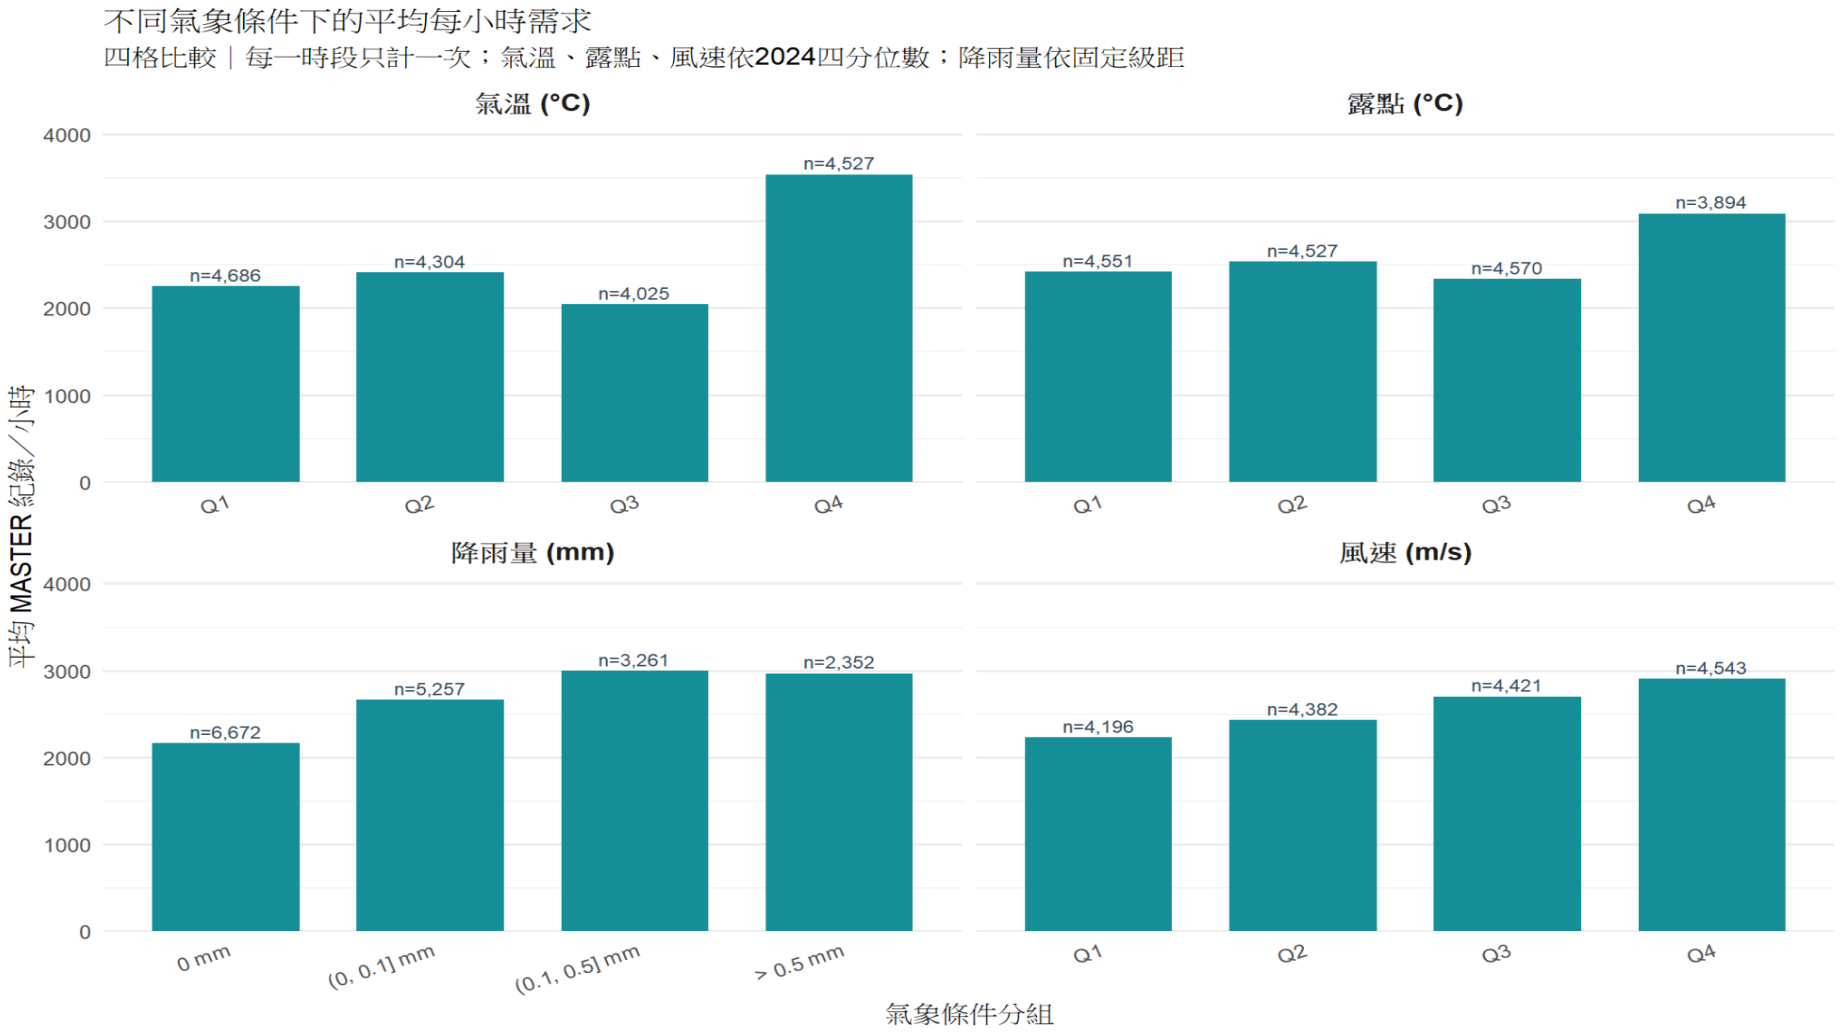
WEEKDAY 尖峰約 17:00，WEEKEND 約 16:00；連假需求在較長時間維持高檔。

連假最後一天：北向需求較高、下午尖峰較早



LAST 在 2024、2025 的暫定分組中都約 13:00 達高峰。

不同氣象條件下，每小時旅次需求呈現差異



原始需求觀察

氣溫 Q4

3,537

筆 / 小時

風速 Q4

2,904

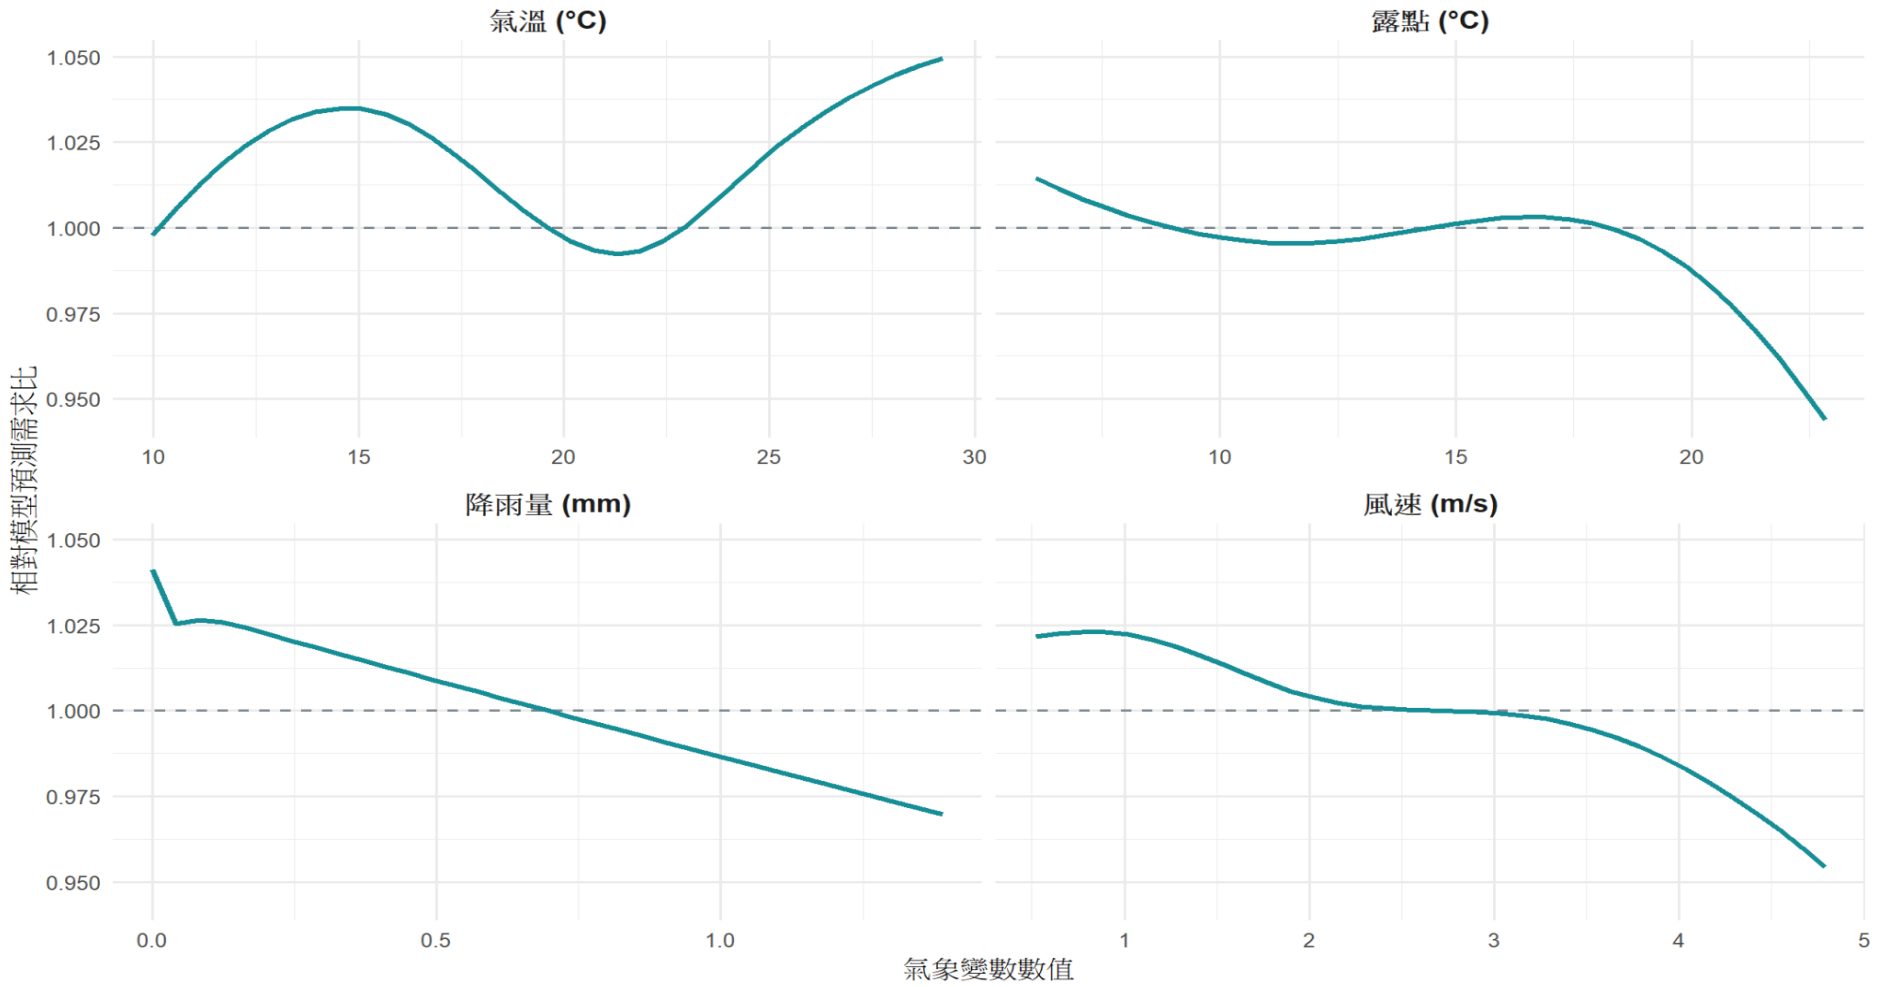
筆 / 小時

只比較原始平均，尚未控制季節、星期與時段。

控制時間後，部分氣象需求關聯方向改變

控制時間及其他氣象條件後，需求如何變化？

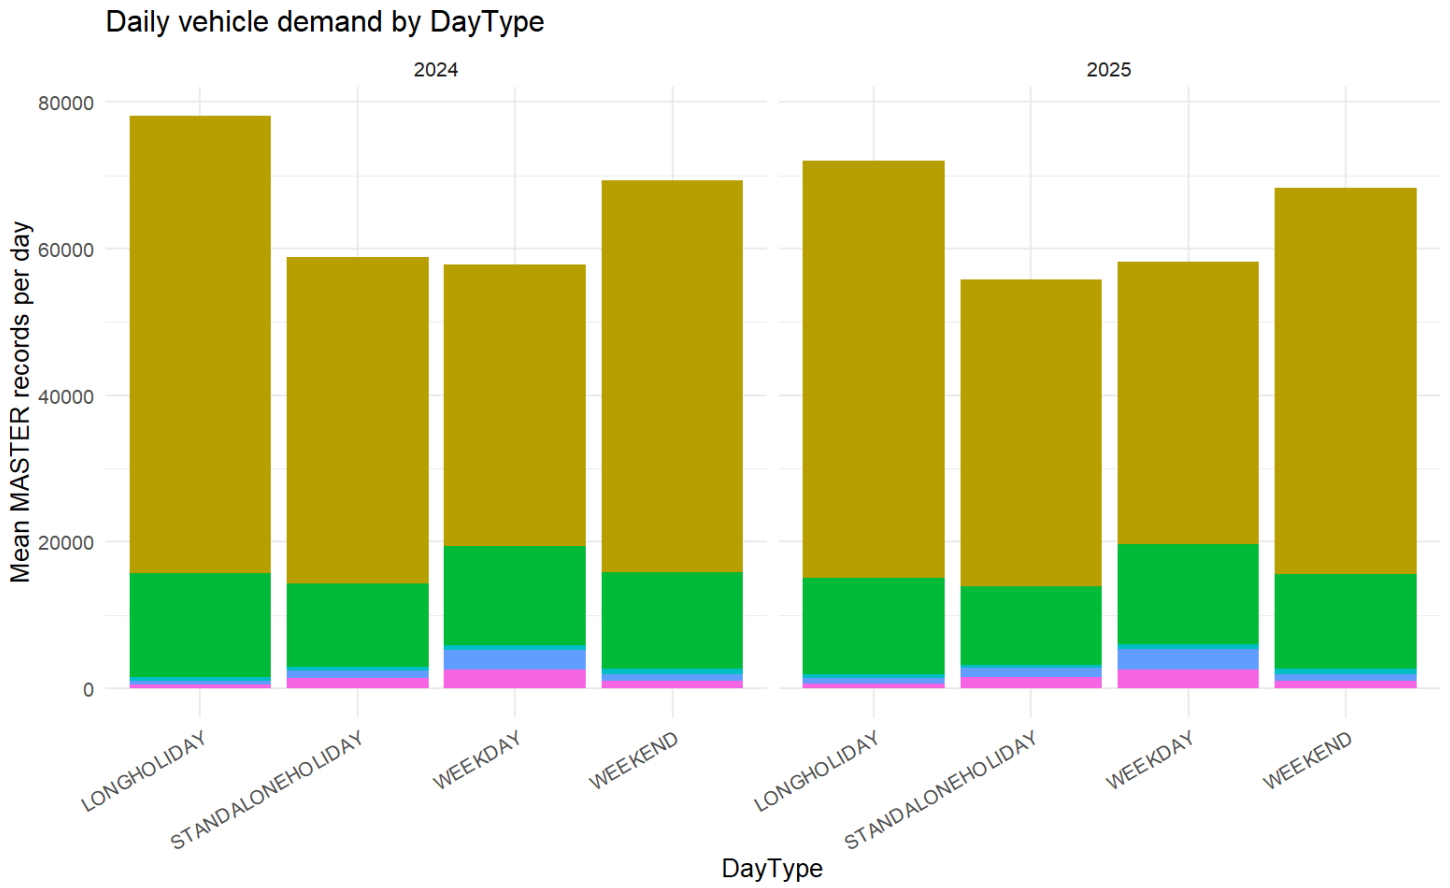
03E 自然樣條迴歸的調整後關聯；各變數以其曲線中間位置=1；非因果估計



調整後高 / 低值比

氣溫	1.052
露點	0.931
降雨量	0.931
風速	0.934

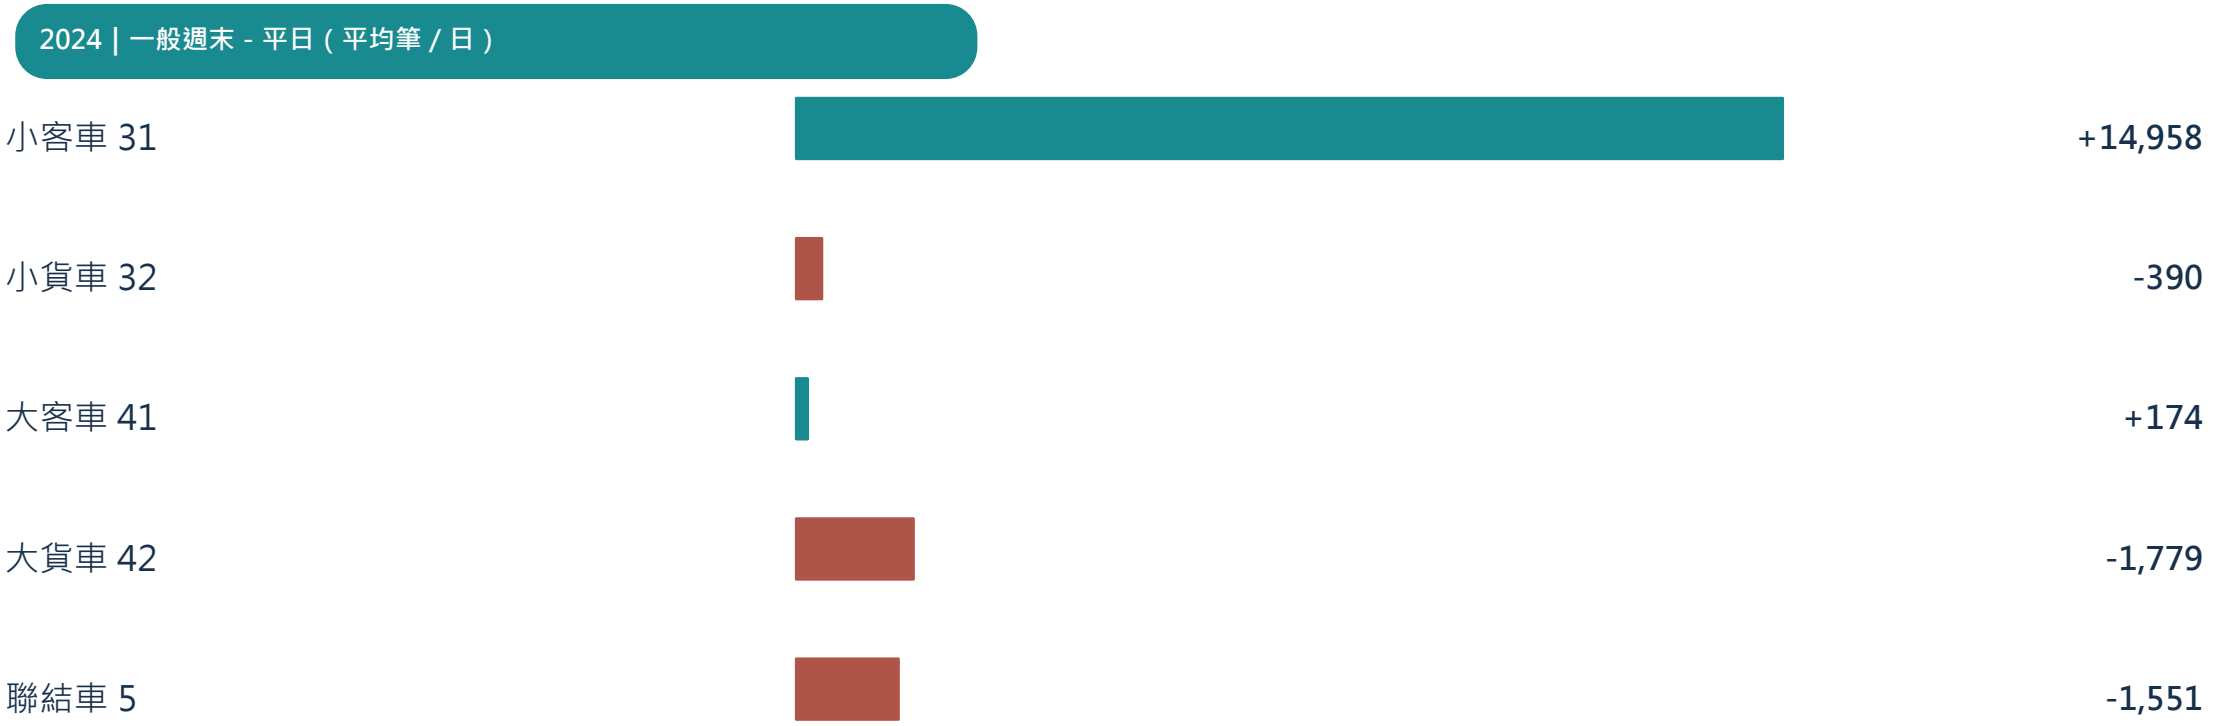
不同 DayType 的車種結構並不相同



欄位	說明
Vehicle Type	車種
31	小客車
32	小貨車
41	大客車
42	大貨車
5	聯結車

一般週末及連假小客車需求較高；大型貨車與聯結車在週末平均需求較低。

週末小客車增量最大；貨運車種則呈下降



2025 方向相近：小客車 +14,179；大貨車 −1,884；聯結車 −1,606。

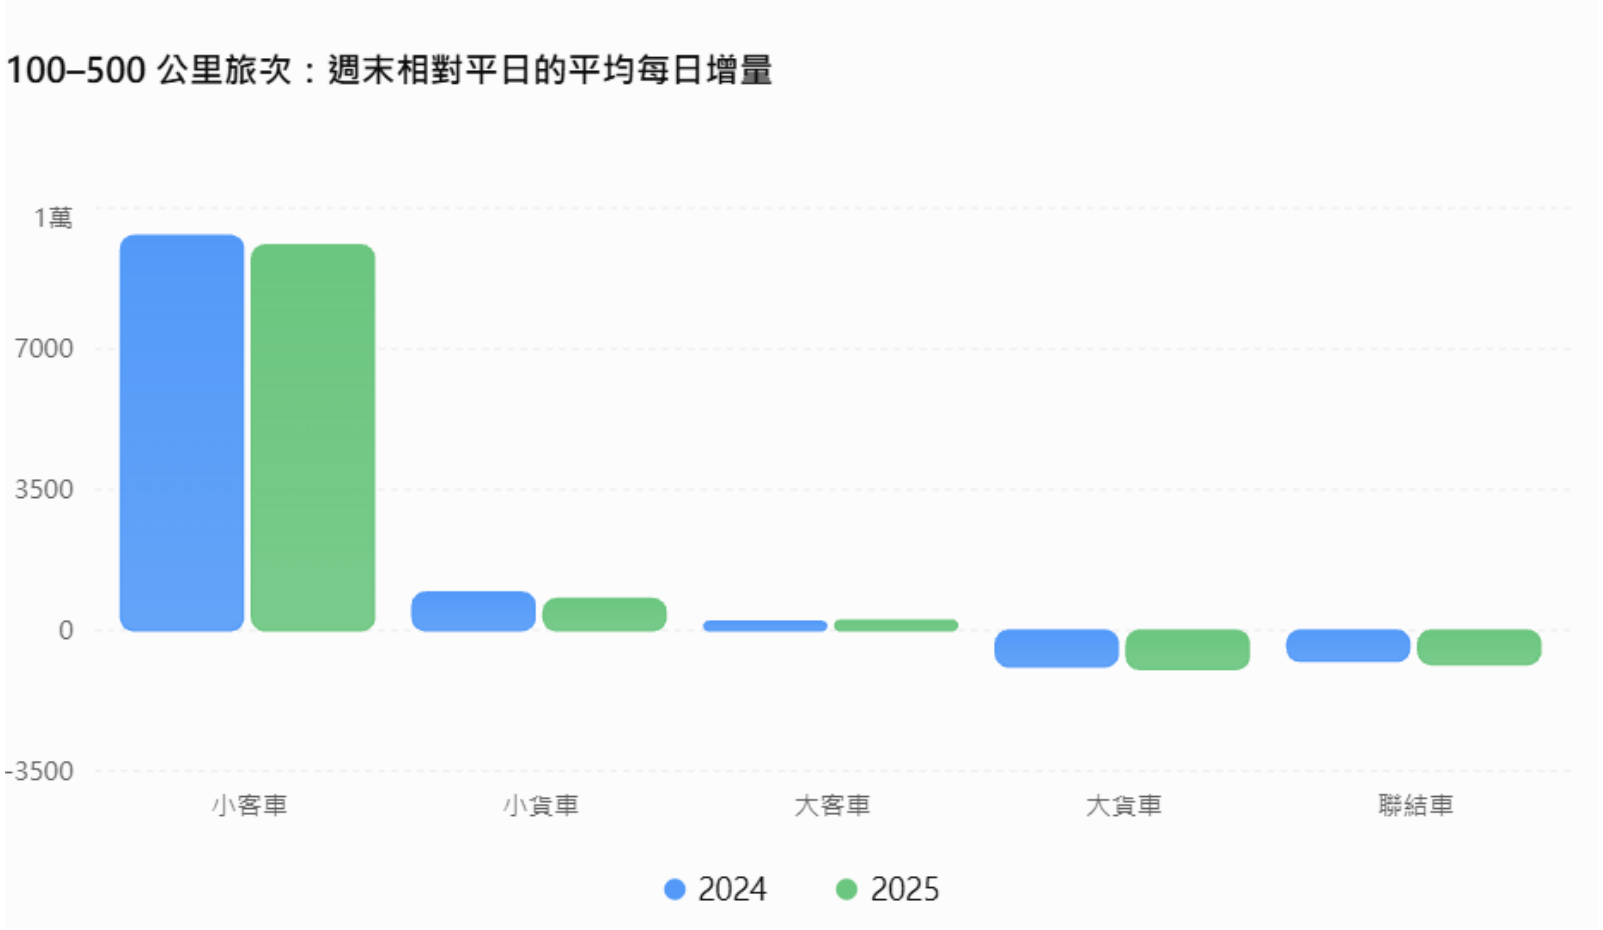
100–500 公里旅次是週末需求增加的重要來源



100–500 km：2024 +9,327　|　2025 +8,813 筆 / 日（未排除 QC 日期）

這是探索性距離分類；固定 OD 里程跨門檻及 >500 km 異常仍需敏感度檢查。

週末長距離需求增加，主要由小客車貢獻



少數重複出現 VehicleID 貢獻大部分旅次紀錄

4,334,000

匿名 VehicleID 數

3 筆

每 ID 紀錄數中位數

53.2%

出現 31 次以上的旅次占比

每 ID 出現次數	VehicleID 占比	旅次紀錄占比
1	29.3%	2.8%
2-5	36.6%	10.7%
6-10	13.8%	10.1%
11-30	13.8%	23.2%
31-100	5.2%	25.5%
101+	1.3%	27.7%

全部 OD 具有明顯的長尾需求

16,350

全部 OD 組合

9,266 56.7% 的 OD

10 筆以下 OD

2024 年最低旅次門檻	符合資格的 OD 組數	涵蓋 2025 年需求
30 筆	4,256	97.80%
100 筆	3,103	97.51%
300 筆	2,182	96.76%
500 筆	1,813	96.14%
1,000 筆	1,314	94.55%

16,350 組 OD → 56.7% 的 OD 不超過 10 筆 → 篩選適合分群的 OD。

EDA 總結｜從探索結果形成研究假設

01 **資料可靠性**

辨識缺漏時段、特殊狀態碼及異常旅次，
避免模型將資料問題誤認為交通現象。

02 **需求結構差異**

平日、週末與連假具有不同時間型態；
車種、距離及 OD 組成也隨情境變動。

03 **形成研究假設**

相同總需求下，不同旅次來源與 OD 群組組成，
是否提供額外的未來低速風險資訊？

核心提問｜在控制時間、天氣、歷史 VD 與總需求後，OD 組成能否改善低速預測？

四種觀點辨識 OD 資料

同一組 OD 資料，對「什麼叫做一群」可以有不同定義；因此不預設單一方法一定最好。

可能納入的 OD 特徵

空間位置 | 旅次量 | 旅次距離 | 時間型態 | DayType | 車種組成

01 K-means

中心距離

反覆更新群平均中心，讓群內平方距離盡量小。

02 Hierarchical

階層關係

從每筆資料各自成群，逐步合併，觀察 dendrogram 的階層結構。

03 DBSCAN

資料密度

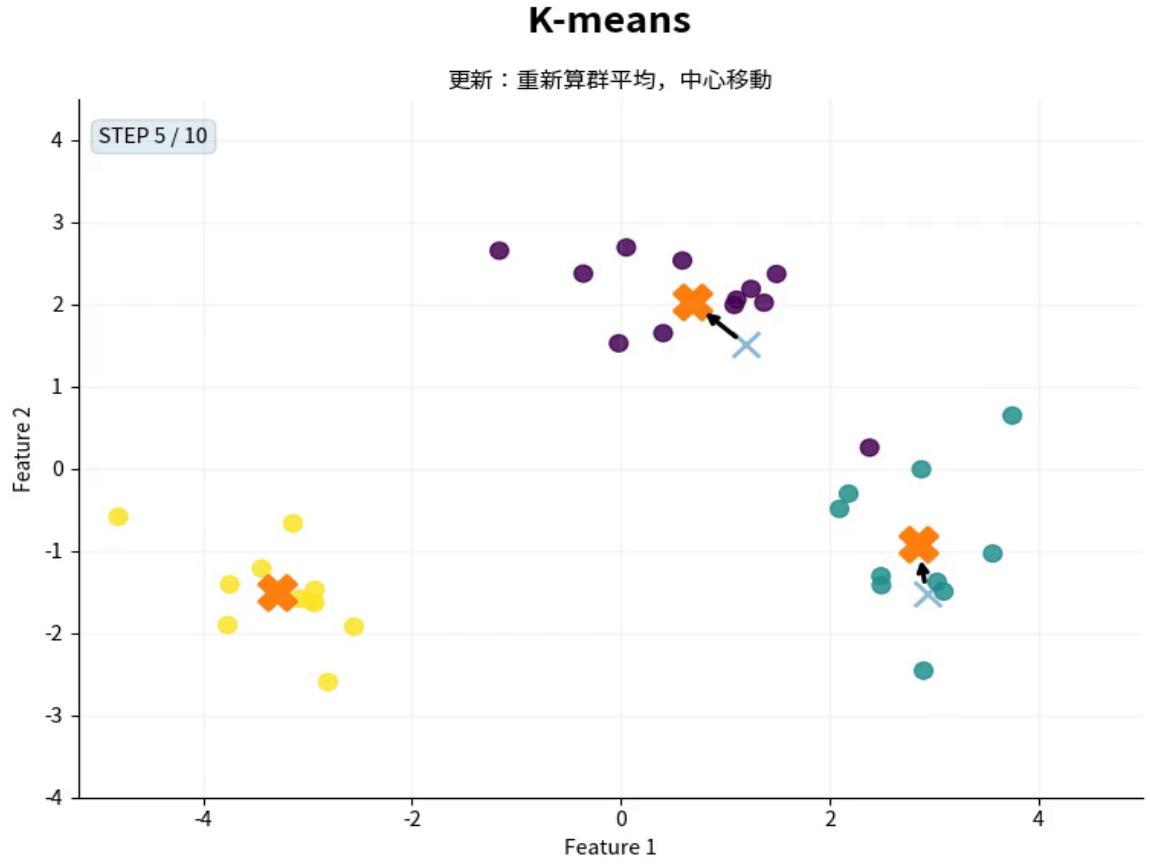
不找中心，而是尋找高密度區域；孤立點可以保留為 noise。

04 GMM

機率分布

用 membership probability 描述群組隸屬，允許模糊邊界。

K-means | 反覆更新群中心，建立基準分群



目標：讓群內差異最小

$$\min_{C_1,\ldots,C_K} \sum_{k=1}^{K} \sum_{i \in C_k} \|x_i - \mu_k\|^2$$

演算法概念

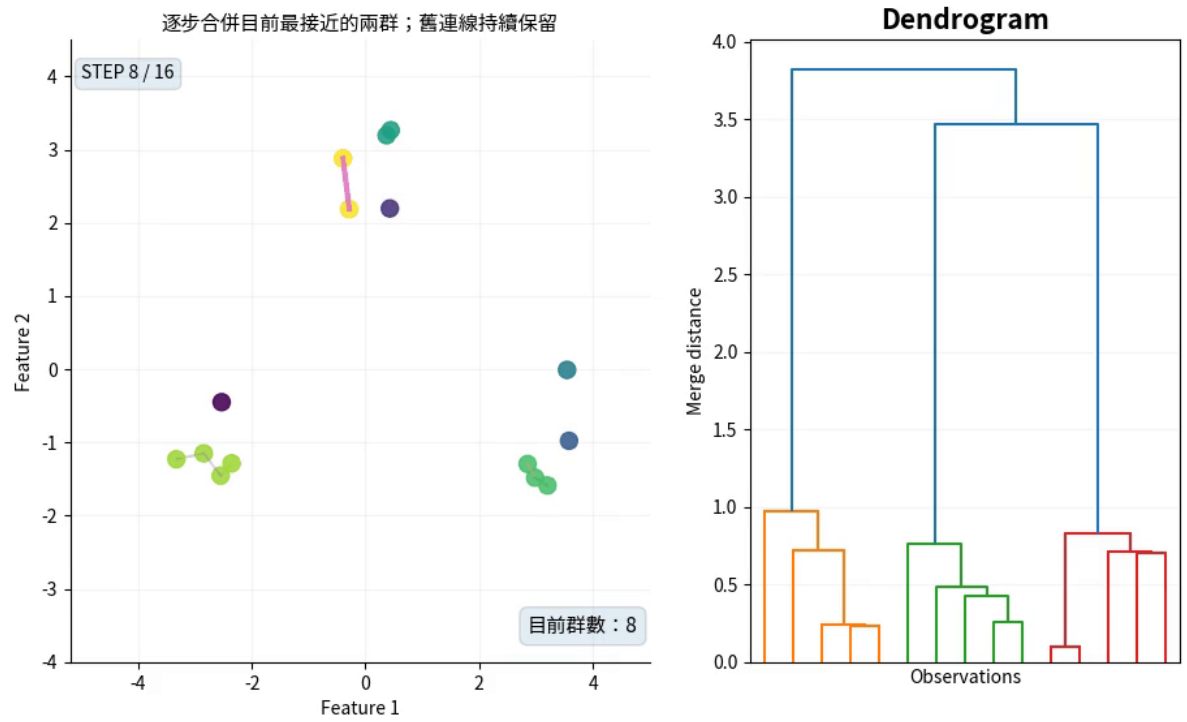
① 先放入 K 個暫時中心
② 分配到最近中心
③ 重新計算群平均
④ 反覆直到不再改變

為什麼先用它？

快速、直觀，適合作為 baseline

注意：需先指定 K；對尺度、離群值與群形狀較敏感。

Hierarchical | 逐步合併，觀察 OD 的階層結構



用途：檢查 K=2、3、4 是否具有自然的階層結構。

完整階層會一路合併到 1 群

$$n \rightarrow n-1 \rightarrow \cdots \rightarrow 1$$

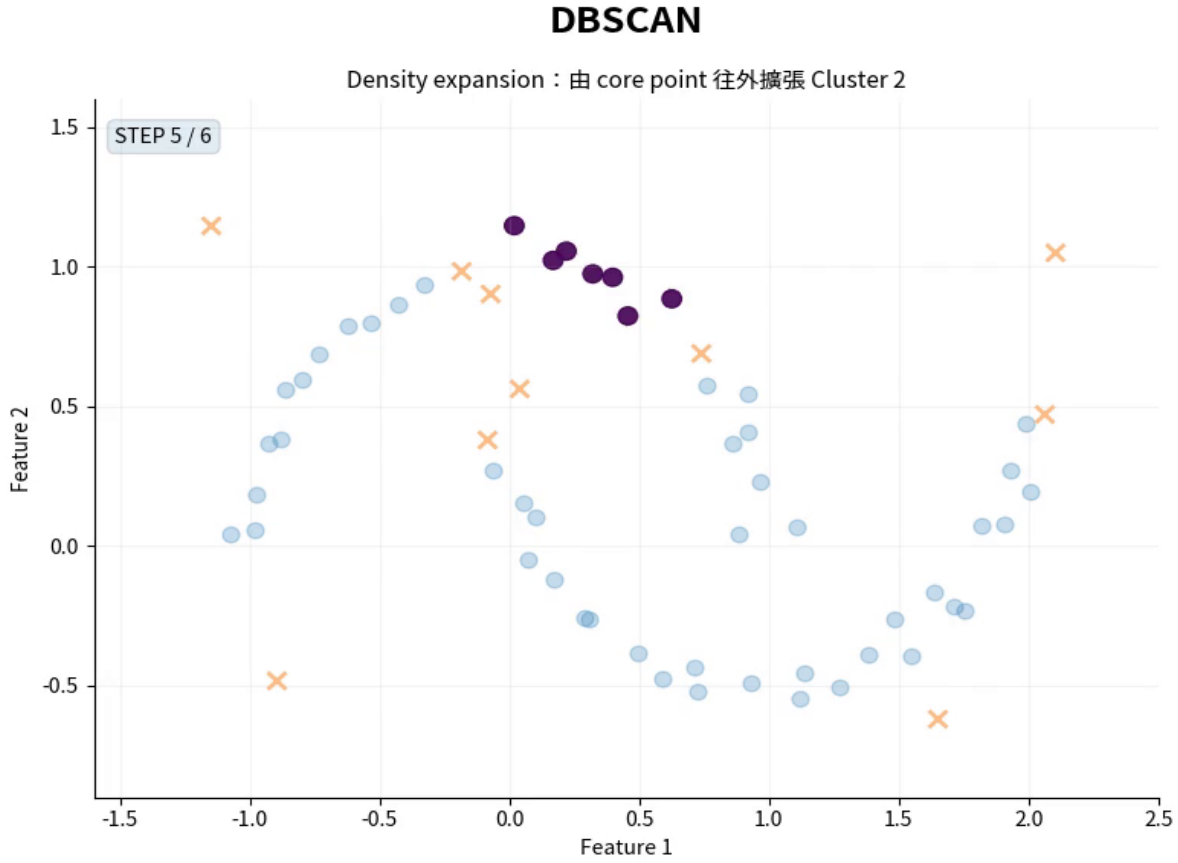
真正的結果：在樹枝狀圖(dendrogram)適當高度切開

例如切成 3 群，而不是把「最後 1 群」當作分群答案。

合併準則

動畫以 Single linkage 呈現「將最近兩群逐步連起來」；正式比較可能使用 Ward linkage，使每次合併造成的群內變異增加最小。

DBSCAN | 不找中心，而是從資料密度形成群組



核心條件

$$N_\varepsilon(x_i) = \{x_j : d(x_i, x_j) \le \varepsilon\}$$

$$|N_\varepsilon(x_i)| \ge MinPts \Rightarrow \text{Core point}$$

三種角色

Core　Border　Noise

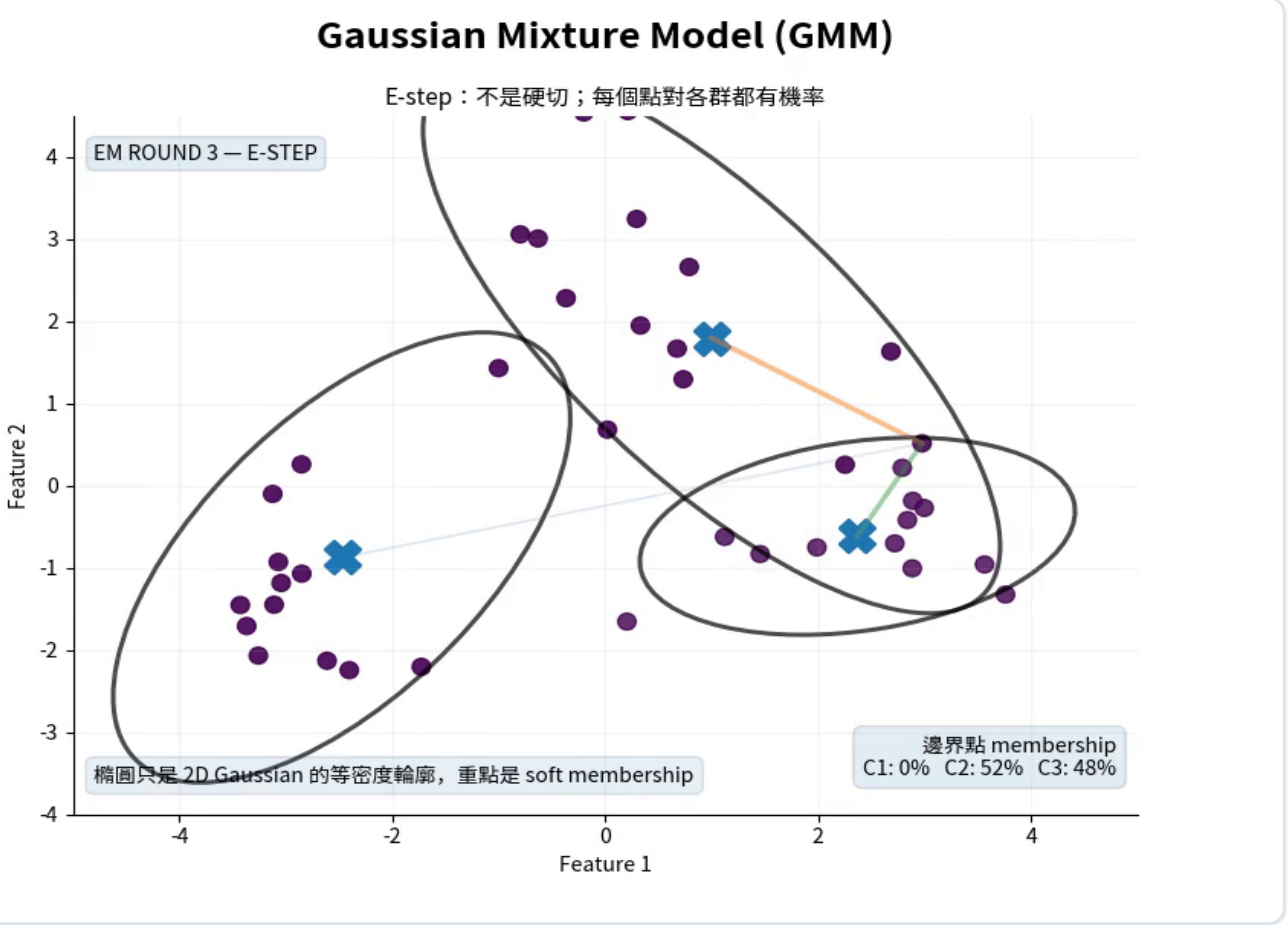
由 core point 向外擴張；孤立資料不必硬塞進某一群。

對 OD 的意義

不需先指定 K，也能辨識不規則形狀的群。

可檢查少量特殊 OD 是「真正的小群」還是零散異常點。

GMM｜用機率描述群組隸屬，允許模糊邊界



混合分布

$$p(x) = \sum_{k=1}^{K} \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k)$$

Soft membership

同一組 OD 可以同時「有點像」不同群：

C1 65% | C2 30% | C3 5%

橢圓代表什麼？

橢圓只是 2D Gaussian 的等密度輪廓，不是硬性的群界。

真正的特色是：群與群之間可以存在連續、模糊的過渡。

XGBoost 與 LightGBM

模型原理與使用契機

本段故事線

01 **GBDT**
共同基礎

02 **XGBoost**
正則化與二階資訊

03 **LightGBM**
Histogram 與 Leaf-wise

04 **比較**
為何兩者都納入

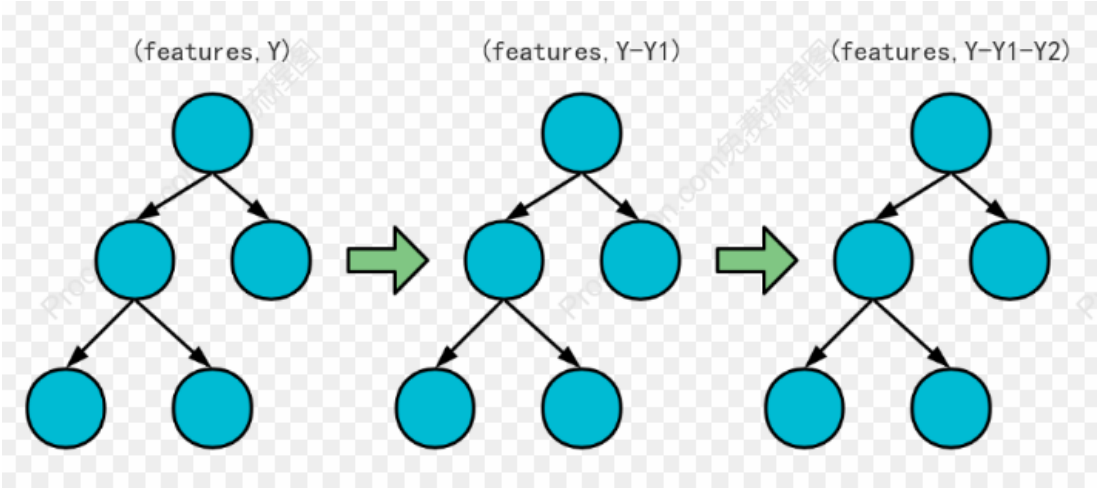
05 **選用原因**
使用模型的理由

共同基礎：梯度提升決策樹(GBDT)

逐輪加入新樹，降低目前模型的損失

$$F_m(x) = F_{m-1}(x) + \eta\, f_m(x)$$

$$p(x) = 1 / [1 + \exp(-F_m(x))]$$



利用樹的葉節點輸出分數，各棵樹累加分數後轉換得到壅塞機率

新樹利用損失的梯度資訊學習修正方向，η 控制每次修正幅度

來源：Chen & Guestrin (2016)，§2

圖片來源:https://www.processon.com/view/616bbfa963768921fa265458

XGBoost：正則化的提升樹

目標函數 = 預測損失 + 樹的複雜度懲罰

$$\Omega(f) = \gamma T + \tfrac{1}{2}\lambda \sum_j w_j^2$$

Depth-wise (or lossguide)

優先分裂較淺的葉節點，逐層向下生長，樹形通常較均衡。

複雜度控制

符號 / 參數	正確定義
$\Omega(f)$	單棵樹 f 的正則化懲罰值
T	這棵樹實際的葉節點數，並非樹的總棵數或深度
w_j	第 j 個葉節點的輸出分數，並非直接的壅塞機率
γ：gamma	每增加一個葉節點所增加的懲罰代價
λ：lambda	控制葉節點輸出分數平方的 L2 懲罰強度

γ、λ 為事先設定的超參數；T、w_j 由訓練過程決定

來源：Chen & Guestrin (2016)，§2–4

LightGBM :樹生長策略不同的新方法

目標函數 = 預測損失 + 樹的複雜度懲罰

$$\Omega(f) = \lambda_1 \sum_{j=1}^{T} |w_j| + \tfrac{1}{2}\lambda_2 \sum_{j=1}^{T} w_j^2$$

Leaf-wise

每次優先分裂增益最大的葉節點，樹可能不對稱

複雜度控制

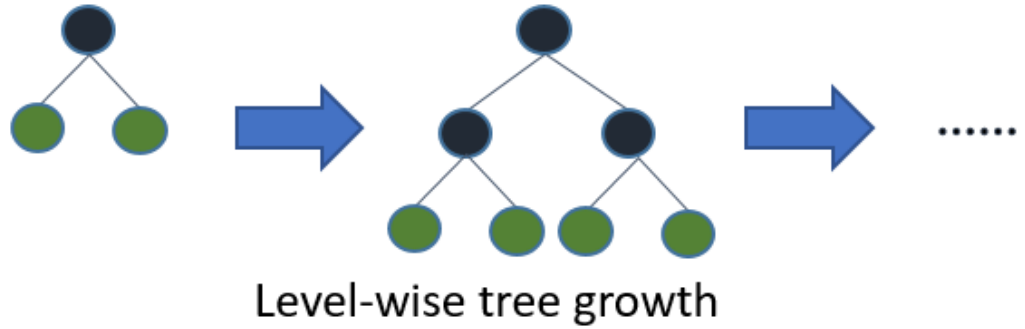
符號 / 參數	意義與作用
w_j、T	第 j 個葉節點的輸出分數、這棵樹的葉節點數
λ_1：lambda_l1	L1 懲罰輸出分數的絕對值
λ_2：lambda_l2	L2 懲罰輸出分數的平方

懲罰係數與生長上限均為超參數，可在驗證資料上挑選

來源：Chen & Guestrin (2016)，§2–4

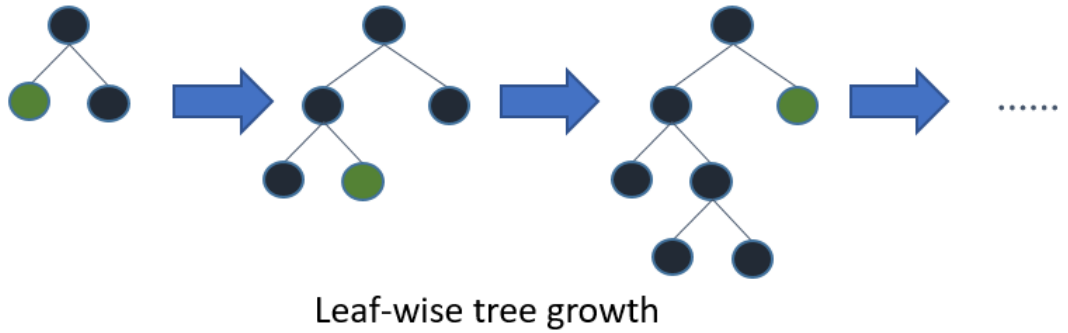
樹的生長策略

Depth-wise：優先較淺的節點



XGBoost 常用 depthwise，也可選 lossguide

Leaf-wise：優先最大增益的葉



LightGBM 採 leaf-wise，須控制葉數與深度

圖：LightGBM 官方 Features；設定差異：兩套件官方文件

XGBoost 與 LightGBM 的差異

比較面向	XGBoost	LightGBM
常用生長策略	Depthwise(or lossguide)	leaf-wise
切點搜尋	支援 hist、approx、exact	以 histogram 為核心
複雜度控制	樹深、葉數、分裂門檻及 L1 / L2 正則化	樹深、葉數、分裂門檻及 L1 / L2 正則化
設計重點	懲罰項與可擴展的樹提升系統	葉優先生長與計算效率

來源：XGBoost / LightGBM 官方文件（查閱：2026-10-20）

本研究選用兩個模型的理由

非線性與交互作用	OD 車流對壅塞的關聯，可能隨尖峰時段或雨量改變
表格資料與比較需求	車流、時間、氣象可作為特徵，通常無須標準化
主流且受認可	實戰穩定性與眾多競賽實績,並且受業界認可
符合龐大數據資料型態	適合在國道中擁有大量VD與OD資料量的模型方法

參考文獻

01 **Chen & Guestrin（2016）**

XGBoost: A Scalable Tree Boosting System. KDD.
DOI: 10.1145/2939672.2939785

02 **Ke et al.（2017）**

LightGBM: A Highly Efficient Gradient Boosting Decision Tree.
Advances in Neural Information Processing Systems 30.

03 **官方技術文件**

XGBoost Parameters；LightGBM Features / Parameters
查閱日期：2026-10-20

04 **使用者提供的延伸閱讀**

CSDN：深度剖析 LightGBM vs XGBOOST 哪个更胜一筹
僅供概念對照，技術差異以原始論文與官方文件核對

完整網址及逐頁講稿收錄於投影片備忘稿

Thanks!